Prédire le décrochage étudiant, et l'expliquer

Un score pour accompagner les étudiants à risque, jamais pour les sanctionner | Projet Challenge 1 · Data Mining · II3-IA / II3-IF · ENSI 2026-2027 | Cas n°10 · **Mnif Nour**

0,93	**90 %**	**0,91**	**4 424**
AUC-ROC du meilleur modèle (XGBoost, jeu de test)	des décrocheurs repérés (seuil 0,3 ; précision 69 %)	AUC dès la fin du 1er semestre (validation croisée)	étudiants, 35 variables 32 % de décrochage

1. Problème métier

Environ **1 étudiant sur 3 abandonne** ses études (32 %) : perte pour l'étudiant, pour l'établissement (financement, places) et pour la société. L'objectif est de **repérer tôt** les étudiants à risque pour proposer tutorat, aide financière ou soutien. Question de décision : *à quel moment peut-on repérer un décrocheur, et au prix de combien de fausses alertes ?*

2. Données

- **UCI** : *Predict Students' Dropout and Academic Success* (id 697), téléchargement automatique.
- **4 424 étudiants, 35 variables** : profil, parents, parcours, finances (bourse, dette, frais), notes S1 et S2, contexte économique. Aucune valeur manquante, aucun doublon.
- Cible à 2 classes : **Dropout = 1** (32,1 %) contre Graduate ou Enrolled = 0 (67,9 %).
- 9 variables « codes » (formation, professions...) traitées en **catégories** (one-hot). Pipeline sans fuite, séparation 80 / 20 stratifiée.

3. Modèles et résultats

Cinq modèles, hyperparamètres optimisés (recherche aléatoire, validation croisée 5 plis). Jeu de test (885 étudiants), seuil 0,5, classe d'intérêt = décrochage :

Modèle	AUC	PR-AUC	Préc.	Rappel	F1
XGBoost	0,935	0,905	0,80	0,84	0,82
Rég. logistique	0,932	0,903	0,79	0,85	0,82
Random Forest	0,928	0,897	0,83	0,80	0,81
KNN	0,903	0,859	0,95	0,49	0,64
Arbre de décision	0,903	0,855	0,75	0,80	0,77

XGBoost et régression logistique sont à égalité (0,3 point d'AUC, dans la marge d'erreur d'un test de 885 étudiants). Variables synthétiques et ensemble de modèles ont été testés : gain inférieur à l'écart-type, donc écartés.

Quand détecter ? AUC en validation croisée (XGBoost) :

Informations disponibles	AUC (CV)
Toutes les notes (S1 + S2)	0,926 ± 0,007
Après 1 semestre (sans S2)	0,908 ± 0,008
Avant tout résultat (sans S1 ni S2)	0,830 ± 0,015

Seuil. Rater un décrocheur coûte plus cher qu'une fausse alerte (un appel). À 0,3, XGBoost repère **90,5 %** des décrocheurs avec 69,3 % de précision (à 0,5 : 83,5 % et 79,8 %).

4. Explications clés (SHAP, LIME, permutation)

- **Variables dominantes** : les **matières validées au S2** (baisse d'AUC d'environ 0,12 si on les mélange), puis les **frais de scolarité à jour** (environ 0,03), puis matières validées au S1, formation, âge et bourse.
- **Sens des effets** : aucune matière validée au S2 ajoute environ +2 (log-odds) au risque, l'effet protecteur se stabilise à partir de 6 matières. Frais **non à jour** : +1 à +2,5. Bourse et bonnes notes réduisent le risque ; endettement et âge élevé l'augmentent.
- **Cohérence avec l'intuition métier** : SHAP et la permutation retrouvent les facteurs attendus (matières validées, frais impayés, bourse) et les taux de l'exploration (87 % de décrochage si frais non à jour contre 25 %). Pour chaque étudiant, l'application affiche le waterfall SHAP, l'explication LIME, leur cohérence (top 5 commun, signes concordants) et une phrase de synthèse automatique.
- **Importance native et permutation divergent** (« Formation » 1re en natif, 4e en permutation), probablement car les colonnes one-hot gonflent les variables à nombreuses modalités : on s'appuie sur la permutation et SHAP.

5. Équité et usage du score

- Variables **sensibles** présentes : genre, âge, nationalité, statut international, situation familiale, études et profession des parents.
- **Poids limité** : nationalité et statut international ne figurent pas parmi les 12 variables principales. La permutation du genre ne fait perdre qu'environ 0,002 d'AUC, contre 0,12 pour les matières validées au S2 : le modèle repose surtout sur les résultats scolaires et les frais.
- **Effets individuels réels** : un âge élevé augmente le risque prédit (jusqu'à environ +0,6 en log-odds) et Gender = 1 aussi (environ +0,2), en cohérence avec les taux observés (45 % contre 25 % selon le genre). À vérifier : taux d'alerte par genre et par tranche d'âge.
- **Risque d'étiquetage** : un étudiant « à risque » pourrait être traité différemment. Le score sert à **proposer une aide**, la décision reste humaine.

6. Recommandations au décideur

- **Modèle** : la régression logistique perd moins de 0,3 point d'AUC face à XGBoost et reste lisible (un coefficient par variable) : recommandée par défaut ; XGBoost pour le maximum de performance.

	Rég. logistique	XGBoost
AUC (test)	0,932	0,935
Lisibilité	un coefficient par variable	boîte noire (SHAP requis)
Usage conseillé	décideur, justification d'une alerte	performance maximale

- **Moment** : agir dès la **fin du 1er semestre** (AUC 0,91). Le repérage avant toute note (AUC 0,83) sert à classer les étudiants par priorité, pas à déclencher une alerte.
- **Seuil** : 0,25 à 0,3 pour viser 9 décrocheurs sur 10 (0,25 retenu en validation croisée), avec un suivi léger (appel) pour les cas incertains.
- **Actions** : contacter en priorité les étudiants avec frais impayés ou dette et peu de matières validées : aide financière, tutorat, échéancier de paiement.

7. Limites

- Les étudiants « Enrolled » sont classés « pas de décrochage » alors que leur avenir est inconnu.
- Un seul établissement (Portugal) : pas de garantie de transfert ailleurs ; pas de validation dans le temps.
- Les corrélations ne sont pas des causes. Des frais impayés peuvent être en partie une **conséquence** de l'abandon (causalité inverse possible).
- La précision reste modeste quand on détecte très tôt : des fausses alertes sont inévitables.
- Des variables sensibles restent dans le modèle : l'équité par groupe doit être contrôlée avant tout usage réel.

8. Livrables. Application Streamlit (données, préparation, modèles, évaluation avec curseur de seuil, explicabilité, prédiction) appelant une **API FastAPI** (/predict, /explain/shap, /explain/lime ; Swagger sur /docs).
Dépôt GitHub : **github.com/nourmnif905/projet-decrochage**